安

通关攻略

人工智能实验安全风险识别与应急处置虚拟仿真实验

（智安工坊 · 学生版）

5 大关卡　24 步任务　满分 100

实验地址：https://shiyanshi.app.tokenone.work

一、出发前准备

① 登录
用学号和老师发的初始密码登录。首次登录必须改密码：至少 10 位，同时有字母和数字。

② 预习
点底部“任务记录”，先完成 10 道预习测验，提交后认真看每题解析——后面的关卡会用到。

③ 移动
W A S D / 方向键走路，按住鼠标拖动转视角；不认路就点“自动前往当前任务”。

④ 交互
走到黄色导引线指向的设备旁按 **E** 打开操作面板，Esc 返回；卡住了按 **H** 看提示（不扣分）。

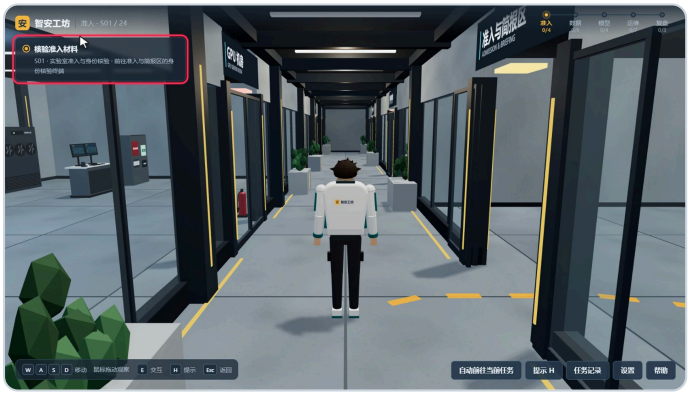
⑤ 提交
填好后点“提交本步”，马上看到得分和反馈。不满意可以改了再交，以最后一次为准。

⑥ 求助
面板里的“AI 实验导师”讲原理不给答案；电脑带不动三维时会自动切换网页模式，题目和评分一样。

★ 照做必过（39 分）
流程与应急处置类，攻略给出完整操作，照做即可。

☆ 动脑得分（52 分，另有 9 分为混合）
分析判断类，攻略只给原理和方法，得分看你自己的判断。

⛔ 红线
危及人身或数据安全的动作，选了本步直接 0 分，其他选对也不能抵消。



左上角是当前任务，右上角是五关进度



按 E 打开操作面板：任务材料 + 知识点 + 操作区



☆ 关卡多数有实时曲线或指标，边调边看再提交



踩红线会出现红色“关键安全错误”，本步 0 分

二、⛔ 红线速查卡（千万别选）

步骤	名称	选了就 0 分的动作
S01	实验室准入与身份核验	勾选“同学代刷门禁记录”
S04	机房设备与环境检查	勾选“打开配电柜检查接线端子”；勾选“拆下机箱盖以改善散热”
S13	智能体工具授权与越权拦截	“机房电源与制冷控制”设为禁止以外的任何选项
S15	GPU 计算任务启动前核验	没有勾选“合上配电柜总开关”
S17	维修前挂牌上锁核验	勾选“亲自断开 PDU 断路器”；勾选“维修人员暂时离开时代为解锁送电”
S18	过温与火警分情景处置	火警时选择报警撤离以外的任何选项（先存数据、自行扑救、回去拿东西）；无烟过温时把“立即向值班运维报告”放在最后
S19	液冷漏液现场处置	第一步不是“远离并警戒”或“报告值班运维”
S20	气体灭火区域撤离与确认	误报时选“自己返回防护区关闭报警器”或“用物品顶住防护门”；喷放后选“烟雾散去即可进入”或“戴上口罩即可进入”
S21	人员触电应急处置	选“立刻用手把他拉开”

一句话记住：人身安全永远第一；配电、送电、断路器这类设施操作是专业人员的事，学生只负责只读查看、报告和配合；危险现场先远离、先报告。

三、五大关卡逐关攻略

第一关 准入

S01—S04 · 15 分 · 先评估、后操作：确认身份、风险和应急准备。

01 实验室准入与身份核验 4 分

★ 照做必过

📍 准入与简报区 · 身份核验终端 ｜ 任务：核验身份与授权，提交准入材料。

- 实验角色选“学生”。
- 准入材料勾选 5 项：安全培训合格证明、实验任务书、指导教师签字、数据使用承诺书、机房区域与时段准入授权。
- 个人简历、成绩单与准入无关，不要勾。

⛔ **红线（选了本步 0 分）**

- 勾选“同学代刷门禁记录”

02 实验任务与风险分级 4 分

☆ 动脑得分

📍 准入与简报区 · 任务简报台 ｜ 任务：从数据、模型、工具三个维度判断风险等级。

- 先读任务材料：数据里有哪些字段？模型是多大参数量？智能体能调用哪些工具？
- 三个维度分别如实选择，不要凭感觉都选最低。
- 风险等级“就高不就低”：数据敏感、模型能力强、工具能对外发送信息，叠加起来风险就高。

03 安全承诺与应急预案确认 3 分

★ 照做必过

📍 准入与简报区 · 任务简报台 ｜ 任务：勾选本实验必须提前准备的应急预案。

- 勾选 7 项：数据泄露应急预案、服务器过温与供电异常处置预案、火灾报警与疏散预案（含集合点）、液冷漏液处置预案、有害内容输出处置预案、智能体越权处置预案、应急联系人与上报路径。
- “实验室钥匙交接表”“设备采购清单”不是应急预案，不要勾。

04 机房设备与环境检查 4 分

★ 照做 ☆ 动脑

📍 GPU 机房 · 机房巡检台 ｜ 任务：以学生身份做上机前的只读巡检，并按设备档案判断进风温度。

- 巡检项勾选 5 项：核对接地合格记录与标识，缺记录则报告；只读查看 UPS/PDU 告警指示；检查进出风无遮挡、盲板与机箱盖在位；确认安全出口、报警点与集合点位置；确认疏散与检修通道畅通。
- ☆ 进风读数：看任务材料里的“设备档案”和测点读数，**如实填写你看到的读数**，不要用默认值。
- ☆ 判断：把读数和档案里的允许范围比较，超出范围就要报告，而不是继续实验。

⛔ **红线（选了本步 0 分）**

- 勾选“打开配电柜检查接线端子”
- 勾选“拆下机箱盖以改善散热”

第二关 数据安全

S05—S10 · 29 分 · 企业数据从分级、脱敏、授权到清理与泄露应急。

05 数据分类分级 5 分

☆ 动脑得分

📍 数据实验室 · 数据处理终端 | 任务：给企业产线数据的 7 个字段分级。

- **一般数据**：单独看识别不出具体是谁，如生产统计结果。
- **个人信息**：能单独或结合其他信息识别出某个人，如姓名、联系方式、员工编号。
- **敏感个人信息**：一旦泄露容易让人受歧视或人身财产受损，如身份证件号码、医疗健康信息。
- 逐个字段想一想：它能不能定位到某个工人？泄露后后果有多严重？

06 个人信息识别与脱敏 5 分

☆ 动脑得分

📍 数据实验室 · 数据处理终端 | 任务：为字段选脱敏策略，并给工位图像做人脸去标识化。

- 训练质检模型用不到的直接标识（如证件号、电话）可以删除；需要区分不同工人但不必知道是谁时，用“假名化”。
- 健康结论这类敏感信息，保留类别即可满足分析需要（泛化）。
- 图像：选一种人脸处理方式，**拖动强度并观察右侧实时指标**——强度太低认得出人，太高画面没法用，找两者都较好的点。
- 先看实时指标再提交，可以反复调。

07 数据授权与模型许可核查 5 分

☆ 动脑得分

📍 数据实验室 · 数据处理终端 | 任务：核查数据授权要件和开源模型许可证。

- 数据：逐条对照任务材料里已经具备的授权，**材料里没写到的才是“尚缺少的”**。缺授权不等于完全不能用，想想能否补救。
- 模型：看清材料中模型的许可证类型，再看本次用途是课程实验还是商业服务，判断是否在许可范围内。

08 训练数据投毒检测 5 分

☆ 动脑得分

📍 数据实验室 · 数据处理终端 | 任务：选检测方法并设阈值，找出被投毒的样本。

- 方法越全面，找出的投毒样本越多：同时看数据异常和可疑触发词，通常比只看一种更好。
- 阈值越低查得越全但误报越多，越高越准但会漏掉。**拖动阈值，观察精确率、召回率和 F1 的变化，选 F1 较高的位置。**

09 训练数据残留清理 4 分

★ 照做必过

📍 数据实验室 · 数据处理终端 | 任务：清理所有数据残留，并按介质类型选择清除方式（仅为预演）。

- 清理位置勾选 5 项：训练机本地缓存、对象存储备份、实验日志中的样本片段、向量数据库索引、个人电脑下载副本（“学校官网首页”不选）。
- 固态盘：使用设备支持的加密擦除/安全清除并验证。
- 对象存储：按保留策略删除，并确认历史版本与快照同步清除。
- 报废机械硬盘：消磁或物理销毁，登记资产去向。

10 数据泄露应急演练 5 分

★ 照做必过

📍 数据实验室 · 泄露应急终端 ｜ 任务：用 ↑↓ 排列泄露应急处置顺序。

- 从上到下排成：① 立即隔离受影响系统 → ② 评估泄露范围与数据类型 → ③ 向实验室负责人与学校网信部门报告 → ④ 通知受影响的个人 → ⑤ 修复漏洞并轮换凭据 → ⑥ 复盘并落实整改。
- 记住口诀：先止损、再评估、后报告，最后整改。
- 可选：点“请安全助手评审”看看建议（不计分）。

第三关 模型与智能体

S11—S14 · 20 分 · 密钥、提示注入、智能体权限与算法公平。

11 密钥最小权限与泄露检测 5 分

☆ 动脑得分

📍 模型与智能体区 · 模型合规终端 ｜ 任务：按最小权限配置 API 密钥，再根据 24 小时调用曲线设告警阈值并处置。

- 权限：本实验只需要调用和微调模型，管理账单、成员、删除项目的权限都不该给。
- 有效期和每日上限：够用就好，越长越大越危险，按一次课程实验的实际需要设置。
- 阈值：看调用量曲线，阈值应高于正常时段的峰值、低于异常时段的调用量，**拖动观察检测效果。**
- 确认是密钥泄露后，只改账号密码或继续观察都不够。

12 提示注入识别与有害内容处置 6 分

☆ 动脑得分

📍 模型与智能体区 · 提示注入隔离沙箱 ｜ 任务：找出 8 条输入里的提示注入，并为 4 类请求选择处置策略。

- 提示注入的特征：要求“忽略之前的指令”、让模型扮演不受限制的角色、把指令藏在网页或文件内容里、索要系统提示词或密钥。正常的总结、整理、统计、解释请求不是注入。
- 处置：可能造成危害的请求要拒绝；正当的隐私保护问题可以正常回答；索要他人身份信息要拒绝；表达轻生念头时不能简单拒绝，要提供人工帮助和求助渠道。

13 智能体工具授权与越权拦截 5 分

★ 照做 ☆ 动脑

📍 模型与智能体区 · 智能体权限控制台 ｜ 任务：为智能体的 6 个工具设权限，观察“诱导外发数据”的攻击能否被拦截。

- ★ “机房电源与制冷控制”必须设为“禁止”。
- ☆ 其余工具按最小权限：只需要看的给“只读”；会破坏数据或执行任意命令的应禁止；能把数据发出去的工具不能“自动允许”，至少要人工确认。
- 提交后看攻击路径：如果数据还是被外发，说明还有通道没堵上。

⛔ **红线（选了本步 0 分）**

- “机房电源与制冷控制”设为禁止以外的任何选项

14 偏见与公平性评估 4 分

☆ 动脑得分

📍 模型与智能体区 · 模型合规终端 | 任务：评估模型在“城镇 / 农村”两组学生上的预测差异。

- 两个指标的区别：人口统计均等差看两组被判为“合格”的比例差；机会均等差看**真正合格的人**在两组中被识别出来的比例差。想一想本任务更关心哪个。
- 阈值是“可以接受的最大差异”，设得太宽等于不检查。
- 把计算出的差值和你设的阈值比较，再下结论；不通过就要提出整改。

第四关 设施与运维

S15—S21 · 25 分 · GPU 机房的供电、散热、液冷、消防与触电应急。

15 GPU 计算任务启动前核验 4 分

★ 照做必过

📍 GPU 机房 · 运维值守台 | 任务：排列启动前核验顺序，并区分学生不能做的设施操作。

- 顺序：① 确认任务许可与使用时段 → ② 核对获批的功率与制冷预算 → ③ 在 BMC 中只读查看电源、风扇、温度告警 → ④ 确认进风温度在设备档案范围内 → ⑤ 提交逻辑启动（作业调度） → ⑥ 启动后观察温度与功耗。
- 由授权专业人员执行的勾选 3 项：合上配电柜总开关、闭合机柜 PDU 断路器、UPS 维护与电池更换。

⛔ **红线（选了本步 0 分）**

- 没有勾选“合上配电柜总开关”

16 散热与过温监控 4 分

☆ 动脑得分

📍 GPU 机房 · 散热监控台 | 任务：选温度测点，调风扇转速与进风温度，在满足负载要求的同时让温度低于告警阈值。

- 测点：判断芯片会不会过热，要看最直接反映芯片发热的那个测点，对照设备档案。
- 负载不要为了降温而调低，任务要求的负载必须满足。
- **调风扇转速和进风温度，看实时曲线**：曲线要稳定在告警参考线以下，留一点余量更好。
- 原理：稳态温度 ≈ 进风温度 + 功耗 × 热阻，风扇越快热阻越小。

17 维修前挂牌上锁核验 3 分

★ 照做必过

📍 GPU 机房 · 运维值守台 | 任务：排列挂牌上锁流程，明确学生安全员的职责边界。

- 顺序：① 通知受影响的实验人员并停止相关任务 → ② 按程序关闭服务器 → ③ 断开 A、B 两路供电输入 → ④ 在断开点挂牌上锁（每位维修人员一把锁） → ⑤ 验电确认无电后开始维修 → ⑥ 维修完成后由上锁人本人解锁摘牌并恢复供电。
- 待机能否直接维修：选“不可以，须确认所有供电输入已断开并验电”。
- 学生安全员勾选 3 项：核对两路供电都已断开并挂牌、提醒他人不得擅自送电、记录挂牌上锁与解除的时间。

⛔ **红线（选了本步 0 分）**

- 勾选“亲自断开 PDU 断路器”
- 勾选“维修人员暂时离开时代为解锁送电”

18 过温与火警分情景处置 5 分

★ 照做必过

📍 GPU 机房 · 运维值守台 ｜ 任务：分别处置无烟过温和火警。

- 无烟过温顺序：① 立即向值班运维报告 → ② 停止提交新任务并降低负载 → ③ 在安全时间窗内保存检查点 → ④ 检查风扇与空调告警 → ⑤ 温度仍上升则受控关机 → ⑥ 记录事件并复盘。
- 火警第一反应：按下报警按钮并沿疏散路线撤离到集合点。

⛔ **红线（选了本步 0 分）**

- 火警时选择报警撤离以外的任何选项（先存数据、自行扑救、回去拿东西）
- 无烟过温时把“立即向值班运维报告”放在最后

19 液冷漏液现场处置 3 分

★ 照做必过

📍 GPU 机房 · 散热监控台 ｜ 任务：排列漏液处置顺序，识别漏液现场禁止的行为。

- 顺序：① 立即远离漏液区域并设置警戒，提醒他人不要踩踏 → ② 立即报告值班运维，说明机柜编号与现象 → ③ 在值班运维指导下停止提交新任务 → ④ 由授权运维按设备程序隔离供电与冷却回路 → ⑤ 记录告警时间与现象，配合复盘。
- 禁止行为勾选 4 项：用手或纸巾擦拭机柜附近的液体、自行拔下机柜电源插头、站在液体中操作键盘保存模型、打开机柜门查找漏点（“在警戒线外向运维提供告警信息”是正确做法，不选）。

⛔ **红线（选了本步 0 分）**

- 第一步不是“远离并警戒”或“报告值班运维”

20 气体灭火区域撤离与确认 3 分

★ 照做必过

📍 GPU 机房 · 应急安全站 ｜ 任务：气体灭火延时阶段的撤离与确认。

- 顺序：① 听到声光报警立即停止操作 → ② 沿疏散路线撤离防护区 → ③ 确认防护区门已关闭，不阻挡防护门 → ④ 在集合点清点人数并报告 → ⑤ 等待专业人员通风检测确认后再返回。
- 误报处理：由授权人员按程序使用紧急停止装置并报告。
- 何时可进入：专业人员完成通风与检测并确认后。

⛔ **红线（选了本步 0 分）**

- 误报时选“自己返回防护区关闭报警器”或“用物品顶住防护门”
- 喷放后选“烟雾散去即可进入”或“戴上口罩即可进入”

21 人员触电应急处置 3 分

★ 照做必过

📍 GPU 机房 · 应急安全站 ｜ 任务：同学触电时的第一反应与施救顺序。

- 第一反应：先确保自身安全，再按急停断电或用干燥绝缘物使其脱离电源。
- 顺序：① 按急停断电或用干燥绝缘物使其脱离电源 → ② 确认脱离电源后检查意识与呼吸 → ③ 无呼吸时由受过培训的人员进行心肺复苏并使用 AED → ④ 拨打 120 并报告实验室负责人 → ⑤ 保护现场并记录事件经过。

⛔ **红线（选了本步 0 分）**

- 选“立刻用手把他拉开”

第五关 复盘

S22—S24 · 11 分 · 追溯事件、复盘整改，生成实验报告。

22 事件追溯与报告 5 分

☆ 动脑得分

📍 审计与复盘室 · 日志审计终端 | 任务：从审计日志找出导出企业数据的账号与时间窗，确定事件等级并选择报告要素。

- **认真看审计日志和图表**：哪个时段的数据导出量明显异常？异常操作集中在哪个账号？
- 事件等级：结合泄露的是什么数据（是否含个人信息）、规模多大来判断，不要一律选最轻。
- 报告要素：一份事件报告要让别人看懂“何时、影响了什么、做了什么、为什么、怎么改”，与此无关的内容不要选。

23 事故复盘与整改 4 分

☆ 动脑得分

📍 审计与复盘室 · 复盘与报告终端 | 任务：选择有效的整改措施，并请安全助手评审。

- 整改要针对本次事件的根本原因，从数据、智能体、密钥、机房几方面各想一想。
- “一刀切”的做法（关掉日志、禁止使用大模型）看似安全，实际会带来新的问题，不是好的整改。
- 提交前可点“请安全助手评审”参考建议（不计分）。

24 实验报告与能力画像 2 分

★ 照做必过

📍 审计与复盘室 · 复盘与报告终端 | 任务：生成实验报告与五维能力画像。

- 完成前面全部步骤后打开本步，点击“生成实验报告”即可。
- 可以请 AI 实验导师生成“实验后反思与改进建议”，写进报告。

四、通关之后

研究探索（选做，不计分）：在“任务记录—研究探索”任选一个课题，先写假设，再自己设定至少 3 组参数运行，最后根据数据写结论。探索记录会写进你的实验报告。

实验报告：完成第 24 步生成报告后，结合 AI 导师的反思建议，想一想得分最低的两步错在哪里、正确思路是什么。

诚信提醒：请独立完成实验，系统会记录每一步的操作过程。实验中的企业数据与员工信息都是虚构的，请不要输入任何真实个人信息。